



Licence Informatique et Vidéoludisme

Exploration du Langage et du Cerveau via l'IA

Rapport de Projet Tutoré

Nicolas Roy & Théo Massenya

Sous la direction de : Mme Revekka KYRIAKOGLU

Université Paris 8

Juin 2026

Plan de la présentation

1. Contexte et Objectifs

- ▶ Le parallèle IA/Cerveau
- ▶ Problématique et hypothèses

2. État de l'Art

- ▶ Modèle MUC (Hagoort)
- ▶ Dimensionnalité Intrinsèque (TwoNN)
- ▶ Le profil à Hunchback z

3. Notre Approche et Méthodologie

- ▶ Modèles et architecture
- ▶ Protocole Sémantique vs Jabberwocky
- ▶ Tokenisation (BPE) et alignement

4. Résultats et Analyse

- ▶ Profils Hunchback et Ramping
- ▶ Discussion neurolinguistique

5. Conclusion

- ▶ Validation & Perspectives

1. Contexte : Le parallèle IA et Cerveau

L'essor des Transformers

- ▶ Succès phénoménal des LLMs sur les tâches linguistiques complexes.
- ▶ Fonctionnement interne souvent décrit comme une **boîte noire**.

Le rapprochement Cognitif

- ▶ Les LLMs et le cerveau humain traitent le même signal : le langage naturel.
- ▶ **Question clé** : L'IA extrait-elle et structure-t-elle les représentations du sens de manière géométriquement analogue au cerveau ?

1. Problématique et Hypothèses

Problématique

Comment caractériser la dynamique d'unification sémantique au sein des couches d'un Transformer, et dans quelle mesure reflète-t-elle les signatures neuronales du cerveau humain ?

Hypothèse 1 : Ramping

Accumulation continue de l'information sémantique le long de la phrase, traduisant une augmentation de la dimensionnalité géométrique locale.

Hypothèse 2 : Cohérence

Une phrase cohérente engendre un surcoût d'unification progressive (ID plus élevée) par rapport à une suite vide de sens (Jabberwocky).


Hypothèse 3 : Hunchback

Le profil n bossu z d'ID (expansion puis compression) sera perturbé par l'absence de cohérence sémantique (Jabberwocky).

2. Principes Neurolinguistiques : Le Modèle MUC

Le modèle **Memory, Unification, and Control (MUC)** de Peter Hagoort décrit le traitement du langage dans l'hémisphère gauche :

- ▶ **Memory (Cortex temporal)** : Stockage et récupération du lexique (structures syntaxiques et sémantiques).
- ▶ **Unification (Gyrus frontal inférieur / Broca)** : Assemblage dynamique et intégration des briques en une structure sémantique globale cohérente.
- ▶ **Control (Cortex préfrontal)** : Gestion de l'attention et des objectifs communicatifs.



Localisation anatomique des composantes du MUC.

2. La Dimensionnalité Intrinsèque (ID) & TwoNN

L'Hypothèse de la Variété (Manifold)

Bien que représentées dans des espaces de très haute dimension (ex : $D = 768$ pour GPT-2), les données réelles sont confinées sur des structures locales de dimension beaucoup plus faible : l'**ID**.

L'estimateur TwoNN (Facco et al., 2017)

- ▶ Calcule le ratio des distances aux deux plus proches voisins pour chaque point : $\mu_i = r_{i,2}/r_{i,1}$.
- ▶ ID estimée à partir de la fonction de

Propriété géométrique clé


L'apprentissage prédictif (minimiser l'erreur du prochain token) force la compression géométrique des représentations sur des variétés compactes et de basse dimensionnalité intrinsèque.

$$d = -\frac{\ln(1-F(\mu))}{\ln(\mu)}$$

2. Dynamique par couches : Le Profil à Hunchback

Ansuini et al. (2019) mettent en évidence une évolution non-linéaire de l'ID à travers les couches des réseaux profonds :

- **1. Phase d'expansion** : Dans les premières couches, l'ID augmente pour à déplier les données d'entrée et séparer les facteurs de variation.
- **2. Phase de compression** : Dans les couches supérieures, l'ID diminue drastiquement pour ne retenir que l'information utile à la prédiction (goulot d'étranglement sémantique).



Profil Hunchback typique dans VGG-16 (Ansuini et al.).

2. Signatures Temporelles de l'Unification

Le phénomène de $\dot{r}$ Ramping $\dot{z}$

- ▶ Chez l'humain (EEG/fMRI), l'unification s'accompagne d'une augmentation graduelle et continue de l'activité neuronale dans l'aire de Broca au cours de la phrase.
- ▶ Desbordes et al. (2023) montrent que les représentations internes des LLMs évoluent de manière similaire : l'ID augmente progressivement mot après mot.
- ▶ **Stimuli sémantiques vs non-sensés** : Le Ramping est soutenu par la cohérence sémantique. L'absence de sens (ex : Jabberwocky) perturbe cette accumulation progressive.

Hypothèse : Le ramping géométrique est une signature de l'effort d'intégration sémantique.

3. Outils et Modèle Expérimental

Modèle de Langage : GPT-2 Small

- ▶ Modèle *Decoder-only* causal (12 couches, $D = 768$).
- ▶ **Justification** : Le masque causal traite le texte de gauche à droite, simulant la linéarité temporelle de la lecture humaine.

Framework Technique

- ▶ **PyTorch** et **Hugging Face** pour l'extraction fine des *hidden states* par couche et par token.
- ▶ **scikit-dimension** pour l'implémentation robuste de TwoNN.
- ▶ **spaCy** pour l'analyse syntaxique (POS Tagging) et la génération.

3. Protocole Expérimental : Sémantique vs Jabberwocky

Objectif

Isoler l'impact du traitement sémantique en maintenant la structure grammaticale et le patron syntaxique strictement identiques.

Groupe Sémantique (N = 500)

- ▶ Phrases extraites de **WikiText-2** (Wikipedia).
- ▶ Langue : **Anglais** (GPT-2 Small étant entraîné sur de l'anglais).
- ▶ Longueur : 8 à 20 mots, syntaxe propre.

Groupe Jabberwocky (N = 500)

- ▶ Remplacement systématique des **mots porteurs** (noms, verbes, adjectifs, adverbes) par des pseudo-mots respectant la phonotactique anglaise.
- ▶ Conservation stricte des **mots-outils** (prépositions, articles, pronoms) et de la syntaxe.

Exemple : "The evolution of language is taught" → "The zumplation of language is carting"


3. Enjeux de la Tokenisation : La Fragmentation BPE

Le biais de la tokenisation

- ▶ L'algorithme BPE fragmente les mots inconnus (pseudo-mots) en sous-tokens (ex : *zumplation* → *zump* + *lation*).
- ▶ Le Jabberwocky comporte en moyenne **2,05 fois plus de tokens** que le sémantique.


Solution : Alignement Temporel Relative

- ▶ Normalisation de la longueur par extraction d'un token représentatif par **décile de position** (10% à 100%).
- ▶ Neutralise le biais du nombre de tokens sur le calcul du ramping.



Histogramme du ratio de fragmentation BPE.

3. Pipeline d'Implémentation du Projet





4. Validation Métrique & Données Synthétiques


4. Évolution par Couche : La Rupture du Hunchback

Sémantique (Bleu) : Hunchback Typique

- **Expansion** : L'ID augmente de 18.65 à **21.14** (couche 6). Démêlage des variables sémantiques.
- **Compression** : L'ID diminue jusqu'à **18.29** (couche 12). Extraction d'un concept abstrait.

Jabberwocky (Rouge) : Explosion Finale

- L'ID ne compresse jamais : elle croît continuellement pour culminer à **30.01** à la couche 12.
- Échec de l'unification : faute de cohérence sémantique, la représentation reste bruitée.



ID par couche sur le dernier token de la phrase.


4. Dynamique Temporelle : Le Ramping de l'ID

Sémantique : Ramping précoce

- ▶ Pente positive et statistiquement significative dès la ****couche 3**** et jusqu'à la couche 11.
- ▶ **Processus d'intégration continue** : l'unification sémantique augmente progressivement la charge représentationnelle.

Jabberwocky : Profil en 2 étapes

- ▶ **Holding Pattern** (10% à 80%) : ID basse et stable. Le modèle ne stocke que la structure syntaxique (peu coûteuse).
- ▶ **Wrap-up final** (90%-100%) : Bond d'ID brutal. Au point final, la fermeture de la proposition force l'unification, provoquant l'explosion dimensionnelle.



Évolution temporelle de l'ID par déciles de position.

4. Confrontation Cognitive : Le rôle du Contrôle

Le Parallèle MUC

Le Ramping sémantique progressif et l'augmentation géométrique dans les couches intermédiaires modélisent de manière convaincante le processus d'**Unification** de l'aire de Broca.

Le Cerveau Humain

- ▶ Face au Jabberwocky, le cerveau humain désengage rapidement son attention sémantique après constatation de l'incohérence.
- ▶ Ce rôle est joué par le ****Contrôle**** cognitif (Cortex préfrontal dorsolatéral).

Le Transformer (GPT-2)

- ▶ Dépourvu de régulation attentionnelle cognitive supérieure.
- ▶ Forcé d'appliquer le même mécanisme uniforme, il s'épuise à chercher un sens aux pseudo-mots, d'où l'explosion de l'ID.

5. Conclusion : Validation des Hypothèses

Validation des hypothèses de travail

1. **Ramping validé** : La dimensionnalité géométrique augmente de manière lente et continue au cours de la lecture sémantique.
2. **Effet de cohérence validé** : L'unification sémantique présente une charge géométrique progressive, confirmée par la comparaison avec le Jabberwocky.
3. **Déformation Hunchback validée** : L'absence de sens bloque la compression géométrique dans les couches finales cachées de GPT-2 Small.

Contribution : L'ID se révèle être un excellent marqueur géométrique macroscopique pour sonder le traitement sémantique des modèles de langage.

5. Limites et Perspectives

Limites de l'étude

- ▶ Modèle restreint en taille (GPT-2 Small, 117M params).
- ▶ Restreint à la langue anglaise en raison de l'entraînement originel du modèle.

Perspectives de recherche

- ▶ **Changement d'échelle** : Reproduire le protocole sur des modèles plus volumineux (ex : Llama 3.1 8B).
- ▶ **Estimateurs d'ID** : Tester d'autres algorithmes locaux (ex : Levina-Bickel, FisherS) pour consolider les mesures géométriques.



~LIV/

Licence Informatique et Vidéoludisme
Université Paris 8